Universidad Centroccidental Lisandro Alvarado
Decanato de Ciencias y Tecnología
Departamento de Sistemas
Lenguajes de Programación (C7)

Interfaz de chat con Python y el Modelo de Lenguaje llama-3.3-70b-versatile

Informe Técnico: Implementación de Inferencia de LLM vía API

Lilianny Ojeda C.I 25.630.844
Bryan Timaure: C.I. 28.779.048
Renny Timaure: C.I. 17.506.751
Análisis de Sistemas, Sección 1

Informe Técnico: Implementación de Inferencia de LLM vía API

1. Objetivo del Proyecto

Desarrollar un script en Python que actúe como cliente de consola para enviar peticiones y recibir respuestas de un Modelo de Lenguaje Grande (LLM), manteniendo un ciclo continuo de interacción usuario-máquina.

2. Arquitectura y Tecnologías Utilizadas

- **Infraestructura:** Se seleccionó Groq debido a su unidad de procesamiento de lenguaje (LPU), que garantiza tiempos de inferencia ultrarrápidos.
- **Modelo Seleccionado:** `llama-3.3-70b-versatile`, un modelo ideal para tareas generales, matemáticas y de razonamiento.

3. Flujo de Ejecución (Lógica del Sistema)

El programa opera bajo un patrón de diseño procedimental con un bucle de eventos continuo:

1. **Autenticación:** Se recupera la clave desde las variables de entorno o parámetros estáticos.
2. **Captura de Input:** Se bloquea el hilo de ejecución hasta que el usuario emita una solicitud usando `input()`.
3. **Transmisión:** Se estructura el *prompt* en un objeto JSON indicando el rol (`"user"`) y se envía vía HTTP al endpoint de la API.
4. **Renderizado:** Se analiza el objeto de respuesta, extrayendo la cadena de texto útil de la propiedad `message.content` para imprimirla de forma limpia en la interfaz.

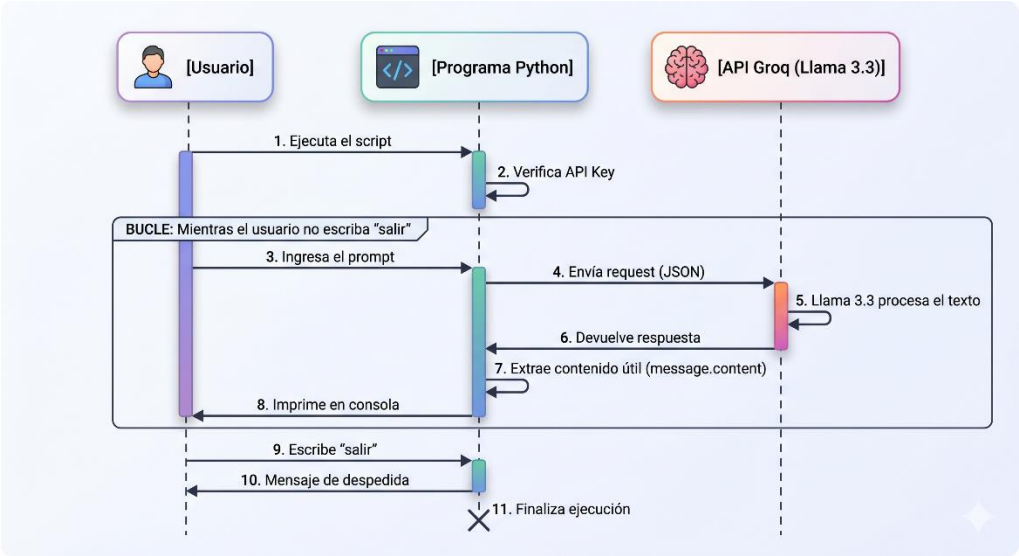

4. Manejo de Excepciones

El código implementa bloques `try-except` para:

- Capturar problemas iniciales de red o configuración del cliente.
- Gestionar de forma elegante caídas del servidor o *timeouts* durante la llamada a la API, evitando que el programa colapse.